



UNIVERSITÀ DEGLI STUDI DI MESSINA

DIPARTIMENTO DI SCIENZE MATEMATICHE E INFORMATICHE, SCIENZE
FISICHE E SCIENZE DELLA TERRA

Bachelor's Degree in Computer Science L-31

Curriculum: Informatica

LAB-07: Neural Networks

Supervisore:

Prof. Giacomo Fiumara

Studenti:

Aurora Fabio – 558520

Mario Parisi – 555657

Sandi Russo – 553675

Anno Accademico

2025/2026

Indice

1	Relazione Finale	1
1	Confronto MLP vs Baseline	1
2	Analisi dei grafici di Loss e Accuracy	1
3	Il ruolo di Softmax e Cross-Entropy	2


Relazione Finale


1 Confronto MLP vs Baseline

Nella fase iniziale di classificazione multiclasse, è stata addestrata una baseline lineare utilizzando una `LogisticRegression` con approccio multinomiale. La baseline costituisce un punto di riferimento fondamentale per valutare l'effettiva utilità di un modello più complesso. Passando al modello `MLPClassifier`, si osserva generalmente un incremento delle prestazioni (accuracy) rispetto alla baseline, specialmente su dataset non linearmente separabili come le immagini dei digit. Questo miglioramento è dovuto alla capacità della rete neurale, grazie ai layer nascosti e alle funzioni di attivazione non lineari (es. ReLU), di mappare relazioni complesse tra le feature in input, superando i limiti intrinseci di un classificatore lineare.

2 Analisi dei grafici di Loss e Accuracy

Osservando i risultati dell'esperimento tra il modello MLP "piccolo" e quello "grande", si evince chiaramente il trade-off tra capacità di apprendimento e generalizzazione. Il grafico della loss mostra che la rete più grande (256, 256) abbatta l'errore di training molto più rapidamente, avvicinandosi allo zero. Coerentemente, l'accuracy di training raggiunge valori prossimi al 100%. Tuttavia, questo comportamento evidenzia un forte rischio di overfitting: il divario prestazionale tra il training set e il test set è più marcato. Al contrario, il modello più piccolo (32,), pur avendo una discesa della loss più graduale, mantiene un gap ridotto tra training e test, dimostrando una migliore regolarizzazione implicita dovuta al minor numero di parametri.





3 Il ruolo di Softmax e Cross-Entropy

Nel contesto della classificazione multiclasse, **Softmax** e **Cross-Entropy** lavorano in sinergia per guidare l'apprendimento della rete. Il layer di output produce dei punteggi grezzi, chiamati *logits*. La funzione Softmax interviene per trasformare questi logit in una distribuzione di probabilità valida, in cui ogni valore è compreso tra 0 e 1 e la somma totale è esattamente 1. Questo permette di interpretare l'output della rete come la "confidenza" assegnata a ciascuna classe. Successivamente, la Cross-Entropy entra in gioco come funzione di costo. Essa confronta la distribuzione di probabilità calcolata dal Softmax con la distribuzione reale (la label codificata in one-hot) e penalizza fortemente le predizioni in cui la rete assegna una bassa probabilità alla classe corretta. Minimizzando la Cross-Entropy durante la backpropagation, la rete impara a massimizzare la probabilità della classe giusta, il che si traduce, a livello pratico, in un aumento dell'accuracy globale del modello.