



UNIVERSITÀ DEGLI STUDI DI MESSINA

---

DIPARTIMENTO DI SCIENZE MATEMATICHE E INFORMATICHE, SCIENZE  
FISICHE E SCIENZE DELLA TERRA

Bachelor's Degree in Computer Science L-31

Curriculum: Informatica

## LAB-08: MultiLayer Perceptron

Supervisore:

Prof. Giacomo Fiumara

Studenti:

Aurora Fabio – 558520

Mario Parisi – 555657

Sandi Russo – 553675

Anno Accademico

2025/2026

# Indice

|          |                                           |          |
|----------|-------------------------------------------|----------|
| <b>1</b> | <b>Relazione Finale</b>                   | <b>1</b> |
| 1        | Confronto tra le configurazioni . . . . . | 1        |
| 2        | Discussione finale . . . . .              | 1        |

# Relazione Finale

## 1 Confronto tra le configurazioni

| Configurazione                       | Val accuracy finale | Val loss finale | Osservazioni                                                                                                                          |
|--------------------------------------|---------------------|-----------------|---------------------------------------------------------------------------------------------------------------------------------------|
| Glorot + ReLU + SGD                  | 0.8852              | 0.3168          | non è ottimale poiché la ReLU azzerava tutti i valori negativi rendendo l'addestramento iniziale più lento.                           |
| He + ReLU + SGD                      | 0.8916              | 0.3114          | si ha un fattore moltiplicativo che bilancia i valori azzerati che porta a una convergenza più rapida e un addestramento più stabile  |
| He + Leaky ReLU + SGD                | 0.9052              | 0.3767          | garantisce prestazioni migliori rispetto alla ReLU standard                                                                           |
| He + ELU + SGD                       | 0.9038              | 0.4257          | produce la val_loss inferiore e l'accuracy maggiore in poche epoche                                                                   |
| He + Leaky ReLU + Momentum           | 0.8960              | 0.3136          | si ha un'accelerazione nella convergenza e un'accuracy migliore                                                                       |
| He + Leaky ReLU + Momentum + Dropout | 0.8954              | 0.3746          | il dropout spegne casualmente una percentuale di neuroni, rallentando l'apprendimento a memoria dei dati e combattendo l'overfitting. |

Tabella 1.1: Caption

## 2 Discussione finale

La combinazione che ha prodotto i risultati migliori è:

$$He + ELU + SGD + momentum = 0.9 + Dropout 0.3$$

L'inizializzazione **He** essendo progettata per mantenere la varianza dei gradienti stabile attraverso i layer con attivazioni asimmetriche, ha permesso una discesa più regolare rispetto al **Glorot**, pensata per attivazioni simmetriche come *tanh*.

Tra le attivazioni invece, **ELU** ha ottenuto la val\_accuracy finale più alta con un valore pari a 0.8970. Questo grazie ai valori negativi che mantengono la media delle attivazioni vicina a zero, riducendo il bias interno ai layer. **Leaky ReLU** ha mostrato maggiore stabilità nelle prime

epoche rispetto a **ReLU**, evitando il rischio di dying ReLU grazie al piccolo gradiente  $\alpha = 0.01$  per input negativi.

L'aggiunta del **momentum** (0.9) ha accelerato significativamente la convergenza: il modello ha raggiunto in poche epoche valori di accuracy che **SGD** plain raggiungeva solo dopo 15–17 epoche, confermando l'interpretazione teorica del momentum come media mobile degli aggiornamenti che accumula inerzia nelle direzioni persistenti del gradiente.

Il **dropout** con tasso 0.3 ha infine ridotto il gap tra training e validation accuracy da 0.047 a quasi zero, eliminando l'overfitting senza penalizzare la val\_accuracy finale in modo significativo.